Research Notes

Step 2 & Step 3實驗

Step 2：哪些 papers 會被排除或合併？

- API 查詢階段已有限制。 查詢帶年份範圍與每次回傳數量上限，因此不是取得資料庫內全部符合條件的論文。OpenAlex、arXiv 的請求還明確指定 relevance 排序，所以 API 回傳可能有相關性順序。
- Provider 轉換階段會略過不完整紀錄。 例如 Semantic Scholar／OpenAlex 沒有 title 的紀錄不會轉成候選 paper。
- Step 2 再檢查年份。 搜尋回傳的論文若有年份、且超出範圍，就排除；年份未知的搜尋結果保留。
- 去重與合併。 依 DOI、來源 ID，或相似標題搭配作者／年份合併
- Snowball 新增論文有更嚴格條件。 年份未知或超出範圍、沒有 abstract、與 PICO 關鍵詞重疊不足，都不加入；已存在的論文不重複加入

Step 2 — Set Recall 與診斷指標

我們依序檢查三件事：Step 2 能否找回資料集指定的答案論文；Step 3 能否把這些論文排到前面；最後 shortlist 是否把它們留下來。這三件事分開評估，避免把搜尋失敗、排序不佳與門檻淘汰混為一談。

設定	Mode A	Mode B
搜尋式	直接使用原始問題，1 條 query	Step 1 整理 PICO 並產生 5 條 queries
搜尋來源	Semantic Scholar、OpenAlex、arXiv	相同來源
評估題目	同一份 80 題	同一份 80 題

Gold paper 是資料集列出的參考答案論文。 每題的答案 ID 清單在 `corpusids`。79 題各有 1 篇答案，另 1 題有 2 篇，因此共有 81 篇 gold。它是評估答案清單，不是 API 回傳集合，也不表示其他論文都不相關。

- 先看結果: Mode B 的整體搜尋與排名指標較高，但它也使用更多 queries、取得更多候選。這是兩種搜尋流程的比較，不能將差距單獨歸因於 Step 3 排序能力。

2. Step 2：答案論文有沒有被找回？

這一步只看論文是否在候選集合中，不看集合內的順序。每題先算 recall，再對全部 80 題取平均。

此處只需要兩個符號：`G_q` 是第 q 題完整的答案清單；`S_q` 是 `step2_raw_papers.json.papers` 的最終候選集合。

$$\text{SetRecall}_q = \frac{|G_q \cap S_q|}{|G_q|}$$

分子＝找到的答案論文數；分母＝該題答案清單原本的論文數。未找到或未能 mapping 的答案仍留在分母。

$$\text{OverallRecall} = \frac{1}{80}\sum_{q=1}^{80}\text{SetRecall}_q$$

Step 2 指標（按題平均，macro）	Mode A	Mode B
直接搜尋 recall（snowball 前）	16.25%	58.75%
最終 Set Recall（snowball 後）	17.50%	60.00%
Snowball 新增命中的 gold 數	1	1

- 怎麼讀：Mode A 的最終 recall 是 17.50%，Mode B 是 60.00%；兩者各有 1 篇 gold 是 snowball 補進來的。這裡的百分比是 80 題的平均

候選集合大小	Mode A 平均／中位數	Mode B 平均／中位數
直接搜尋集合(API 搜尋結果經年份處理、去重與 DOI 補全後)	82.325／97	500.100／496.5
最終候選集合(加入snowball)	99.325／106	504.100／500

3. Step 3：找回的答案能否排到前面？

未命中題目不呼叫 Step 3,有 gold 但 Step 3 失敗或 skip 的題目，也在 overall 計零。

Step 3 執行狀態（按題計）	Mode A	Mode B
Step 2 命中至少一篇 gold	14／80	48／80
完成 Step 3	14／14 命中題	48／48 命中題
因 Step 2 未命中而跳過	66 題	32 題

3.1 評分與排序方式

LLM 分別輸出 relevance、quality、recency/impact 的 1–5 整數。Python 計算加權分數，採 half-up 四捨五入到小數點後兩位：

$$\text{composite} = \text{round}_2(0.50\,\text{rel} + 0.30\,\text{qual} + 0.20\,\text{recency})$$

主要排序使用 relevance；composite 排序作對照。兩者都讀 `step3_screening_all.json.papers`，保留 included、borderline、excluded。`paper.id` 只是同分時的穩定排序鍵。

- **Relevance 排序：** `(-rel, -composite, paper.id)`。
- **Composite 排序：** `(-composite, paper.id)`。

3.2 四個排名指標各回答什麼？

指標	問題	分子／分母或計算方式
R@5／R@20	前 5／20 名涵蓋多少答案？	前 k 名的 gold 數／該題完整 gold 數
MRR	第一篇答案排得多前面？	每題第一個 gold 名次的倒數，再平均；沒有命中為 0
nDCG@10	前 10 名是否把答案放在較前位置？	實際折扣增益／以完整 gold 數計算的理想折扣增益

令 L_q 為第 q 題完整候選排名。以下是單題公式；MRR 是各題 RR 的平均，並不除以 gold 數。

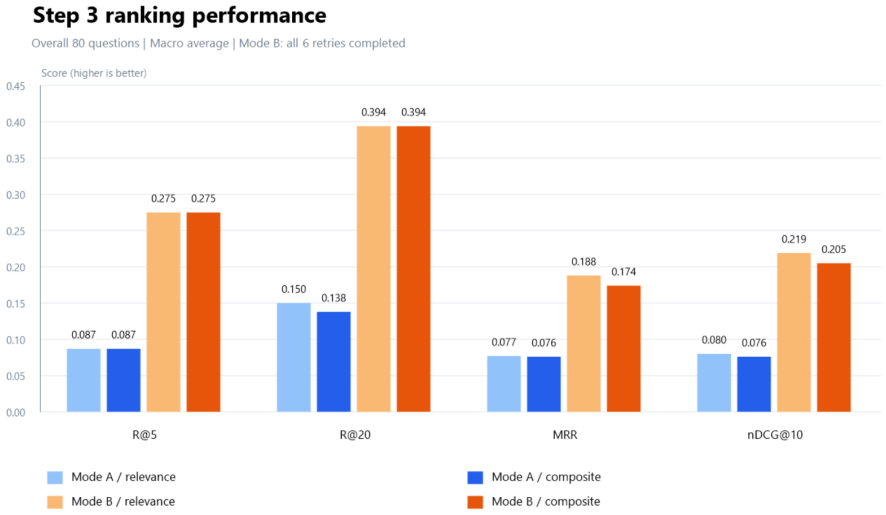
$$\text{R@}k_q = \frac{|G_q \cap L_q[1..k]|}{|G_q|}$$

$$\text{RR}_q = \begin{cases} 1/\min\{i : L_q[i] \in G_q\}, & \text{有命中} \\ 0, & \text{無命中} \end{cases} \qquad \text{MRR} = \frac{1}{80}\sum_q \text{RR}_q$$

$$\text{nDCG@10}_q = \frac{\sum_{i=1}^{\min(10,|L_q|)} \mathbf{1}[L_q[i] \in G_q]/\log_2(i+1)}{\sum_{i=1}^{\min(10,|G_q|)} 1/\log_2(i+1)}$$

3.3 主要結果：全部 80 題（overall）

回答完整流程對 80 題的表現。所有數值都是按題平均。



Mode／排序	R@5	R@20	MRR	nDCG@10
Mode A／relevance	0.087	0.150	0.077	0.080
Mode A／composite	0.087	0.138	0.076	0.076
Mode B／relevance	0.275	0.394	0.188	0.219
Mode B／composite	0.275	0.394	0.174	0.205

3.4 補充結果：只看 Step 2 有命中的題目（hit-only）

Mode／排序	有效題數	R@5	R@20	MRR	nDCG@10
Mode A／relevance	14	0.500	0.857	0.442	0.456
Mode A／composite	14	0.500	0.786	0.436	0.433
Mode B／relevance	48	**0.458**	**0.656**	**0.314**	**0.365**
Mode B／composite	48	**0.458**	**0.656**	**0.290**	**0.341**

評估範圍	排序方式	題數	R@5	R@20	MRR	nDCG@10
Overall	BM25	80	0.263	0.381	**0.210**	**0.237**
Overall	relevance	80	**0.275**	**0.394**	0.188	0.219
Overall	composite	80	**0.275**	**0.394**	0.174	0.205
Hit-only	BM25	48	0.438	0.635	**0.350**	**0.395**
Hit-only	relevance	48	**0.458**	**0.656**	0.314	0.365
Hit-only	composite	48	**0.458**	**0.656**	0.290	0.341

3.5 BM25 baseline 與 Step 3 固定 top-100 比較

官方固定 corpus 的 BM25取得每題 top-100，再讓 Step 3 對**完全相同的 100 篇**評分。候選集合不變，主要比較的是排序能力

1. 下載官方 `query`（597 題）與 `corpus_clean`（64,183 篇），鎖定 Hugging Face revision；另存官方 BM25 原始碼的 commit 與 SHA256。
2. 使用官方 title＋abstract 格式、NLTK 斷詞、英文停用詞移除、Porter stemming、rank-bm25 BM25Okapi（k1=1.5、b=0.75、epsilon=0.25）與官方 NumPy 排序規則，計算完整題集 BM25 baseline。
3. 對目前凍結的 80 題，每題固定其 BM25 top-100，轉成新的 `step2_raw_papers.json`。不使用 API 搜尋、snowball，也不補入未找回的 gold。
4. 所有 80 題都執行原 Step 3，不依 gold 是否命中決定要不要呼叫模型。比較 BM25、relevance、composite，保留每題结果、tokens、時間與失敗紀錄。

題型	題數	指標	我們重跑	論文 Table 3
inline_broad	120	R@20	37.4%	37.4%
inline_specific	231	R@5	38.5%	38.5%
author_broad	35	R@20	48.6%	48.6%
author_specific	211	R@5	62.6%	62.6%

相對 BM25（overall）	ΔR@5	ΔR@20	ΔMRR	ΔnDCG@10
relevance	+0.188	+0.125	+0.140	+0.153
composite	+0.175	+0.112	+0.127	+0.140

排序方式	R@5	R@20	MRR	nDCG@10
BM25	0.525	0.675	0.412	0.450
Step 3 relevance	**0.713**	**0.800**	**0.551**	**0.603**
Step 3 composite	0.700	0.788	0.538	0.589

4. Shortlist：答案最後有沒有留下來？

排名高不保證會通過 composite 入選門檻。這一步另外讀 `step3_shortlist.json.papers`，檢查後續 pipeline 真正能取得的論文。

指標	分子	分母
Shortlist recall	shortlist 中的 gold 數	資料集全部原始 gold 數
Gold 保留率	shortlist 中的 gold 數	Step 2 已找回的 gold 數
候選保留比例	shortlist 論文數	Step 2 最終候選論文數

Shortlist recall 的分母為 81 篇 gold；gold 保留率的分母是各模式已找回的 gold 數。

入選結果（micro）	Mode A	Mode B
Shortlist recall	11/81＝13.58%	45/81＝55.56%
Gold 保留率	11/14＝78.57%	45/49＝91.84%
候選保留比例	250/7946＝3.15%	5767/40328＝14.30%

- 怎麼讀：A 找回 14 篇 gold，最後保留 11 篇；B 找回 49 篇，最後保留 40 篇。
- Gold 保留率衡量的是找回後有多少被留下；shortlist recall 衡量的是全部答案最後留下多少。

Gold 最終狀態（按篇計）	Mode A	Mode B
included	11	45
borderline	0	2
excluded	3	2
已找回但未完成評分	0	0
未找回	67	32

Provider 查詢執行狀況

來源	A 成功／查詢數	A 失敗／查詢數	B 成功／查詢數	B 失敗／查詢數
semantic_scholar	80/80	0/80	375/400	25/400
openalex	80/80	0/80	395/400	5/400
arxiv	80/80	0/80	389/400	11/400

Time and Token used

Step 2 平均為 4.53 分鐘／題。

Step 3：

- 平均每題 539.5 篇候選、約 46 次 LLM 呼叫。
- Input：231,430 tokens／題。
- Output：44,002 tokens／題。
- 合計：275,432 tokens／題。
- LLM 呼叫耗時合計平均：387.5 秒，約 6.46 分鐘／題

Step 8 實驗

Data collection:

1. Target paper 怎麼搜尋

程式透過 OpenAlex 的 `/works` 搜尋，使用關鍵字 `medicine OR biology OR clinical OR biomedical`，設定發表日期為 2026-01-01 至 2026-06-30 (generator 訓練截止之後)，要求資料類型是 `article`、有 abstract、主要出版來源是 journal，並排除 paratext。

搜尋結果依**發表日期由新到舊**排列，先找符合期刊名稱規則的論文，收滿要求的題數

期刊名稱規則包含 Nature、Science、Cell、Lancet、JAMA、NEJM、BMJ、PLOS Medicine，且接受部分系列期刊，例如 Nature Methods、Nature Communications、Cell Reports

2. 領域與日期怎麼確認

資料集標記為 biomedical，但最初搜尋主要靠關鍵字與期刊規則，**沒有逐題強制檢查 OpenAlex 領域分類**。

3. 模型 cutoff 的檢查標準

程式讀取你提供的 registry：`local_qwen_3.8B` 登記 cutoff 為 2024-10-29，將下一個月第一天 2024-11-01 作為允許的 target 起始日，因此設定的 2026 年區間會通過檢查。

但這個日期與 registry 名稱，尚未核實是否對應實際使用的 `qwen3.8` 模型。目前只完成「依登記日期檢查」，不能宣稱 zero contamination

4. References 怎麼抓

每題讀取 target 在 OpenAlex 的 `referenced_works`，也就是該論文引用的文獻，再批次取得各 reference 的資料。它不是另外搜尋相似論文，也不是抓引用 target 的後續論文。

程式最多處理 500 個 reference IDs，每批解析 50 個。Abstract 由 OpenAlex 的 `abstract_inverted_index` 還原。每篇至少保存：

`paperId、title、abstract、year、citationCount、publicationTypes`，另保留可取得的 DOI、venue、URL 與 `openalex_type`。

5. References 實際過濾標準

目前會刪除 citationCount 缺失或 **小於 5** 的文獻、沒有 abstract 的文獻、沒有 title 的文獻，以及被 OpenAlex 標成 review、editorial、letter、book、book-chapter、paratext、peer-review、erratum、retraction 的文獻。

6. 每題的 5 篇 refs 怎麼選

先從過濾後的 refs 依 `paperId` 排序，再按保存的 seed 旋轉順序，以等距位置選出 5 篇。這是可重現的固定取樣，不是引用數最高的五篇，也不是由 LLM 挑選的五篇。

每題都有 5 篇 refs 與一段 target idea

7. Target idea（金標）怎麼產生

使用 Gemma `gemma4:31b`，按照你指定的 IdeaBench 萃取 prompt，把 target abstract 壓成一段，以 `Hypothesis:` 或 `Given that` 開頭，保留主要研究想法與高層次發現，省略細節數值。所以這裡的金標是從人類論文摘要經 LLM 萃取的想法

- **P1 baseline**：每題把相同 5 篇 references 的標題與摘要交給 Qwen，用一個生成 prompt 產生 n 個研究想法；n 等於該題 P2 實際產生的 gap 數。
- **P2 pipeline**：將同樣 5 篇 references 注入 Step 2，跳過線上搜尋，再跑 Steps 3–7。每個 gap 各生成一份 Step 8 hypothesis spec，再各壓縮成一段研究想法，因此有幾個 gap，就有幾個 idea

比較時，兩者都不能看到 target paper 或金標 idea，而且必須使用相同 references、相同 generator

Novelty、Feasibility 是 Insight Score（0–1，越高越好）

novelty／feasibility 的「排名」由 LLM judge 做，「分數計算」由 Python 做

每題將 target idea＋n 個生成想法匿名混合排序，Gemma 分別依 novelty 與 feasibility 排序；Python 再根據 target 的名次計算：

$$\text{Insight Score} = \frac{r_{\text{target}} - 1}{n}$$

Target 主題	n	P1 Novelty	P2 Novelty	P1 Feasibility	P2 Feasibility	P2 Rubric
RNAbpFlow: base pair-augmented SE(3) flow matching for conditional RNA 3D structure generation	2	0.000	0.000	0.667	0.500	4.30
TUSC3 serves as a rate-limiting gatekeeper of a glycan-mediated ER triage checkpoint for BMP4/Dpp	2	0.000	0.000	1.000	0.500	4.40
Antagonistic histone H2A variants and autonomous heterochromatin formation shape epigenomic patterns in Arabidopsis	2	0.000	1.000	1.000	1.000	4.35
Distinct and compensatory roles of STAG1 and STAG2 in post-mitotic genome refolding	3	0.667	0.000	0.333	1.000	4.13
Systematic discovery of pathogen effector functions across human pathogens and pathways	3	0.250	0.333	0.667	0.750	4.27
A natural programmable metamaterial controls 3D curvature of compound eyes	3	0.000	0.000	1.000	1.000	4.10
Severe anaemia and invasive bacterial infections in Kenyan children: a 26-year hospital surveillance observational study	3	1.000	1.000	0.500	0.167	4.57
Longitudinal single-cell and TCR	3	0.000	0.000	0.917	0.750	4.20

Target 主題	n	P1 Novelty	P2 Novelty	P1 Feasibility	P2 Feasibility	P2 Rubric
repertoire profiling characterizes clonal entrapment in patients with pMMR/MSS locally advanced rectal cancer						
Dysregulation of the TFEB-ATP6V0C axis in microglia exacerbates α-synuclein pathology through impaired lysosomal acidification in Parkinson's disease	3	0.167	0.167	1.000	0.000	4.47
Integration of Three-Dimensional Cell Culture Techniques and Photobiomodulation for Supportive Differentiation of Adipose-Derived Stem Cells into Smooth Muscle	3	0.333	0.583	1.000	0.750	4.33
Vaccination elicits HIV broadly neutralizing antibodies in primates	3	0.417	1.000	0.500	0.750	4.33
Boundary geometry controls a topological defect transition that determines lumen nucleation in embryonic development	3	0.000	0.583	1.000	0.917	4.23
High-dose furmonertinib as first-line treatment for untreated EGFR-mutated advanced NSCLC with central nervous system metastases: A phase 2 trial	3	0.917	0.667	0.917	0.750	4.10
Targeted Protein Degradation of NUDT5 Dissociates Catalytic Inhibition from Protein Loss in 6-Thioguanine Response	3	0.000	0.000	0.917	0.417	4.10
Immunotherapy with B28, an antibody to Aβ	3	1.000	1.000	1.000	1.000	4.20

Target 主題	n	P1 Novelty	P2 Novelty	P1 Feasibility	P2 Feasibility	P2 Rubric
oligomers, potently decreases amyloid plaques, microgliosis, and memory decline in APP knock-in mice						
HOXC9 accelerates esophageal squamous cell carcinoma progression via OTUD1-FABP5-mediated lipid metabolic reprogramming	3	0.333	0.000	0.917	0.167	4.30
Patient-derived organoids reveal ductal dysfunction and CFTR-modulator responses in chronic pancreatitis	2	0.833	0.667	1.000	0.833	3.75
Clinical decision support in hematological malignancies using a case-grounded AI agent	3	1.000	0.000	0.667	0.000	4.40
Progression of dengue during an outbreak (2024) in Dhaka, Bangladesh: a hospital based longitudinal study	3	1.000	1.000	0.667	0.000	4.13
Trends in autoimmune rheumatic disease diagnoses before and after the COVID-19 pandemic in England: a population-based cohort study using OpenSAFELY	3	1.000	0.833	0.000	0.250	4.30

題數	P1 Novelty	P2 Novelty	P2−P1	P1 Feasibility	P2 Feasibility	P2−P1
20	0.446	0.442	-0.004	0.783	0.575	-0.208

P2 的 10 項 rubric

Rubric 是 1–5 分。每題 P1、P2 使用相同 n

題目類型	題數	每題spec數	合計
產生2個gap	4	2	8
產生3個gap	16	3	48
全部	**20**	—	**56**

類別	指標	平均分
Problem	Clarity：問題清楚度	4.93
Problem	Relevance：領域相關性	4.96
Problem	Originality：問題原創性	4.02
Problem	Feasibility：問題可研究性	4.61
Problem	Significance：研究重要性	4.07
Method	Clarity：方法清楚度	3.70
Method	Validity：方法能否回答研究問題	4.52
Method	Rigorousness：方法嚴謹性	4.77
Method	Innovativeness：方法創新性	**2.86**
Method	Generalizability：方法可推廣性	4.09
全部	**56份spec × 10項評分的平均**	**4.25**

Time and Token used:

已記錄用量	Input tokens	Output tokens	合計
Generator(`qwen3.8`)	890,483	452,107	1,342,590
Judge(`gemma4:31b`)	3,158,063	153,181	3,311,244

時間項目	包含內容	平均時間
Step 8生成	Qwen讀取背景與locked gap，生成一份spec	32.59秒／份
前置pipeline	Step 0、2準備，加上Step 3、4、6、7；Step 5採摘要模式	約60.6秒／題
Rubric評分	Gemma逐項評一份spec的10個指標	47.08秒／份
P1匿名排名	對P1想法與target idea做novelty、feasibility排名	35.06秒／題
P2匿名排名	對P2想法與target idea做novelty、feasibility排名	34.76秒／提

Checkpoints for each step

What we retrieve from each step:

☑

Step 0：研究主題與 PICO

從 `step0_session_config.json` 取：

- `topic`：研究主題。
- `pico.population`、`pico.intervention`、`pico.comparison`、`pico.outcome`、`pico.setting`：界定研究對象、介入、比較、結果與情境。
- `field_type`：rubric 選用 biomedical 或 cs_engineering anchors。

上述 topic／PICO 會提供給 Step 8 generator

topic／PICO也提供給 rubric judge

☑

Step 3：保留的相關文獻

同一份 `step3_shortlist.json`，兩條路徑取的欄位不同。

Step 8 生成直接取 `papers[].id`、`papers[].journal`，組成「citation key → journal」清單，供期刊推薦參考。

Rubric 評分取 `papers[].title`、`papers[].year`、`papers[].abstract`，組成 related papers context。最多取 shortlist 前 12 篇，每篇 abstract 最多 600 字元。

Step 4：引用對應

Step 8 生成從 `step4_citation_keys.json` 取：

`[paper_id].key`

再和 Step 3 的 `[paper_id].journal` 配對。例如形成 `Anon2021 → Nature Methods`

Step 6：研究現況

Step 8 生成讀整份 `step6_sota_review.md`，作為 prompt 的 `sota`

Rubric 評分則優先讀 `step6_sota.json`，明確抽出：

- `executive_summary_en`：整體研究現況摘要。
- `trends_en`：方法或研究趨勢。
- `converging_en`：一致的研究發現。
- `diverging_en`：分歧的研究發現。
- `themes[].number`、`themes[].title_en`：主題編號與名稱。
- `themes[].consensus_en`：主題共識，最多 240 字元。
- `themes[].methods_en`：主要方法，最多 160 字元。

組合後的整份 SOTA context 最多 4,000 字元

Step 7：選中的研究缺口

Step 8 生成先從 `checkpoints.json` 取：

- `decisions["3"].decision.lock`：要處理的 gap ID。
- `decisions["3"].decision.drop`：捨棄的 gaps。
- `decisions["3"].decision.constraint`：設計限制。

再到 `step7_gaps.json` 的 `gaps[]`，找出 `id == lock` 的那一列。整列都送給 generator，包括 `id`、`rank`、`composite`，以及內層 `gap` 的描述、支持／反對證據、重要性、三項分數與理由。從 `step7_gap_analysis.md` 的 frontmatter 取 `topic`，存在時優先於 Step 0 topic。

Rubric 它先讀 `step8_hypothesis.json.locked_gap`，再回 Step 7 找出對應整列，作為 locked gap context

Step 8：被評的 spec

Rubric 從 `step8_hypothesis.json` 取 `locked_gap` 與內層 `spec`，再依當次 metric 抽取部分欄位：

- Problem Clarity：`spec.research_questions`、`gap_summary_en/zh`。
- Problem Relevance：`research_questions`、`gap_summary_en`、`executive_summary_en`。
- Problem Originality：`gap_summary_en/zh`、`gap_selection_rationale_en`、`research_questions`。
- Problem Feasibility：`research_questions`、`risks`、`scope_in`、`gap_summary_en`。
- Problem Significance：`executive_summary_en/zh`、`gap_summary_en/zh`、`gap_selection_rationale_en/zh`。
- Method Clarity／Validity：`hypotheses`、`research_questions`、`conceptual_framework_en/zh`。
- Method Rigorousness：`hypotheses`、`conceptual_framework_en`、`traceability`。
- Method Innovativeness：`conceptual_framework_en/zh`、`hypotheses`、`gap_summary_en`。
- Method Generalizability：`scope_in`、`scope_out`、`scope_rationale_en/zh`、`hypotheses`、`conceptual_framework_en`

做絕對 rubric 評分時，程式把整個 `hypotheses[]` 提供給獨立評審 Gemma